PROYECTO FINAL

DEEP LEARNING PARA LA INTELIGENCIA ARTIFICAL

Sistema Progresivo de Análisis de Sentimiento y Generación de Resúmenes

Aplicado al dataset Amazon Fine Food Reviews

Presentado por:

Alfredo Argueta Interiano	AI252944
Giovanni Alexander Escobar	EM252920
Ivo Luis Orellana Girón	OG252913
Marlon Alexander Palacios Diaz	PD252876
José Rodrigo López Torres	LT170438

Fecha de entrega: *18 de Octubre de 2026*

Contenido

1. Introducción y descripción del problema 3
1.1 Objetivos del proyecto 4
1.2 Justificación del uso de Deep Learning 4
2. Descripción del dataset 5
2.1 Fuente y metadatos 5
2.2 Columnas utilizadas 5
2.3 Distribución de la variable objetivo 5
2.4 Estadísticas de longitud del texto 6
2.5 Preparación y split 7
2.6 Estrategia frente al desbalance 7
3. Metodología y arquitecturas utilizadas 8
3.1 Etapa 1 — Modelo base: MLP + TF-IDF 8
3.2 Etapa 2 — Arquitectura profunda: 1D-CNN 8
3.3 Etapa 3 — Modelos preentrenados: RoBERTa zero-shot 9
3.4 Etapa 4 — Componente generativo: T5-small zero-shot 9
3.5 Etapa 5 — Fine-tuning parcial y despliegue 10
4. Experimentos realizados 11
4.1 Análisis exploratorio (Etapa 1) 11
4.2 Protocolo de evaluación 11
4.3 Análisis de errores (MLP) 11
5. Resultados 13
5.1 Comparativa — Clasificación de sentimiento 13
5.2 Comparativa — Componente generativo 14
5.3 Análisis cualitativo del componente generativo 15
5.4 Despliegue final 15
6. Limitaciones y trabajo futuro 16
6.1 Limitaciones identificadas 16
7. Conclusiones 16

1. Introducción y descripción del problema

El análisis automático de opiniones de consumidores se ha convertido en una herramienta central para el comercio electrónico. Plataformas como Amazon reciben millones de reseñas que, interpretadas a escala, permiten tomar decisiones sobre inventario, detección de productos defectuosos, recomendaciones personalizadas y detección temprana de fraude. La lectura manual es inviable: un producto popular puede acumular decenas de miles de reseñas, con longitudes y estilos muy heterogéneos.

Este proyecto desarrolla un sistema de Deep Learning aplicado que combina dos capacidades complementarias sobre reseñas de productos:

- Clasificación de sentimiento multiclase (negative / neutral / positive) — permite ordenar, filtrar y agregar reseñas según su polaridad.
- Generación automática de resúmenes — convierte reseñas largas en títulos cortos que pueden mostrarse en listados, dashboards o interfaces de búsqueda.

El sistema se construye de forma progresiva, siguiendo las cinco etapas del programa del curso. Cada etapa añade una capacidad que las anteriores no tenían, permitiendo comparar cuantitativamente el aporte de cada arquitectura o técnica.

1.1 Objetivos del proyecto

- Establecer una línea base de desempeño con redes neuronales clásicas (MLP) y cuantificar sus limitaciones frente al problema de análisis de sentimiento.
- Implementar una arquitectura profunda especializada (1D-CNN) y comparar cuantitativamente su desempeño contra el modelo base.
- Integrar un modelo Transformer preentrenado (RoBERTa) en modo zero-shot para evaluar la capacidad de transferencia directa de modelos preentrenados al dominio.
- Incorporar un componente generativo (resúmenes) con T5-small, justificado funcionalmente dentro del sistema.
- Adaptar el modelo generativo al dominio mediante fine-tuning parcial y exponerlo a través de una interfaz web funcional con Gradio.

1.2 Justificación del uso de Deep Learning

El problema cumple los tres criterios establecidos en los lineamientos:

1. Dispone de datos reales a gran escala (más de 500 mil reseñas)
2. La complejidad del texto natural justifica el uso de arquitecturas profundas — modelos lineales sobre bag-of-words no capturan negación, sarcasmo ni contexto secuencial
3. Se presta a ampliaciones progresivas: cada etapa del curso añade una capacidad que los modelos anteriores no tenían (patrones locales, atención bidireccional, generación, adaptación de dominio).

2. Descripción del dataset

Se utilizó el dataset público Amazon Fine Food Reviews publicado por Stanford SNAP Group. Contiene reseñas de productos de la categoría "comida fina" de Amazon recolectadas entre octubre de 1999 y octubre de 2012.

2.1 Fuente y metadatos

Atributo	Valor
Fuente original	Stanford SNAP — Amazon Fine Food Reviews
Disponibilidad	Kaggle / HuggingFace Datasets
Tamaño del archivo	~300 MB (Reviews.csv)
Total de reseñas	568 454
Período	Oct. 1999 — Oct. 2012
Usuarios únicos	~256 000
Productos únicos	~74 000

2.2 Columnas utilizadas

Columna	Tipo	Uso en el proyecto
Id	int	Identificador único de la reseña
ProductId	string	No usada para modelado
Score	int 1-5	Variable fuente del sentimiento (1-2 → negative, 3 → neutral, 4-5 → positive)
Summary	texto corto	Utilizado para la tarea generativa
Text	texto libre	Entrada principal para ambas tareas

2.3 Distribución de la variable objetivo

Tras la conversión Score a sentimiento, la distribución observada es fuertemente desbalanceada hacia la clase positiva, lo cual es característico de reseñas de productos en e-commerce:

Clase	Frecuencia	Proporción
positive	443 776	78.07 %
negative	82 037	14.43 %
neutral	42 640	7.50 %
Total	568 453	100.00 %

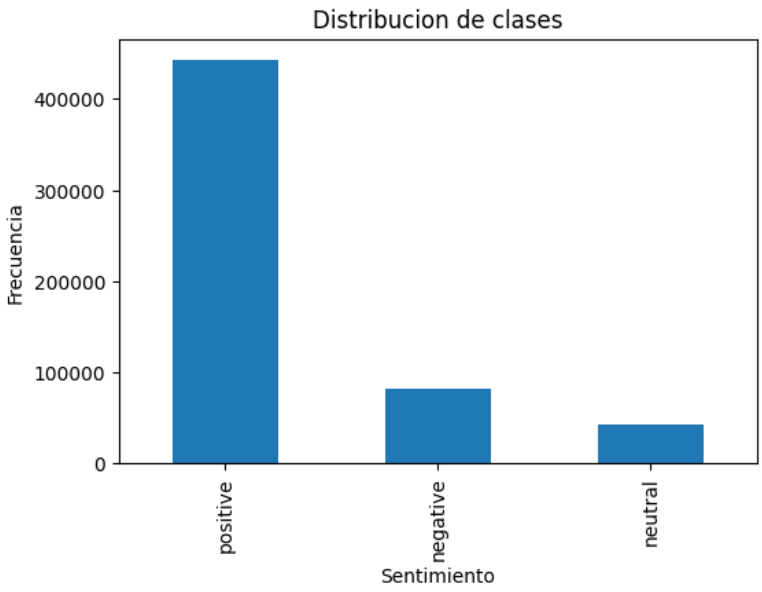

Ilustración 1 — Gráfico de barras — Distribución de clases (exportado de NB1)

2.4 Estadísticas de longitud del texto

Sobre el texto limpio (en caracteres):

Estadística	Valor
Media	417
Mediana	290
Percentil 75	506
Máximo	20 517
Mínimo	12

Los Summary originales son extremadamente cortos (media 22 caracteres, mediana 20), lo cual tiene implicaciones directas sobre la evaluación del componente generativo: ROUGE penaliza cuando el modelo genera frases más largas que las referencias, aunque el contenido sea semánticamente correcto.

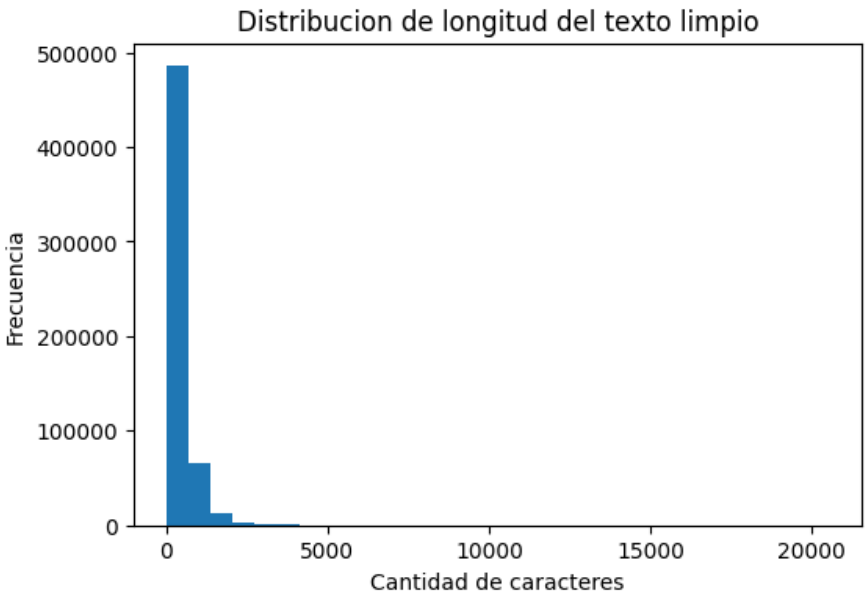

Ilustración 2 — Histograma — Distribución de longitud del texto por clase (exportado de NB1)

2.5 Preparación y split

- Limpieza: minúsculas + eliminación de caracteres no alfabéticos + normalización de espacios.
- Split estratificado 70 / 15 / 15 (train / validación / test) preservando la proporción de cada clase.
- Semilla fija (random_state=42) para reproducibilidad.
- Resultado: 397 902 train, 85 283 val, 85 268 test.

2.6 Estrategia frente al desbalance

Dado que la clase positive domina con 78 %, un clasificador trivial que siempre prediga "positive" ya lograría ~78 % de accuracy. Para no enmascarar el fallo en clases minoritarias, en todas las etapas se reportan métricas complementarias:

- Accuracy y F1 weighted: sensibles al desempeño sobre la clase mayoritaria.
- F1 macro: penaliza fuertemente si el modelo falla en clases minoritarias (neutral, negative).

En la Etapa 1 (MLP) se aplicó además undersampling controlado de la clase positive a 120 000 muestras, reduciendo el sesgo del optimizador hacia la clase mayoritaria sin perder toda la información del conjunto.

3. Metodología y arquitecturas utilizadas

El sistema se construyó de forma progresiva: cada etapa extiende las capacidades de la anterior introduciendo una arquitectura o técnica distinta. Los outputs de cada etapa (splits, métricas, modelos) se exportan como artefactos reutilizables por las siguientes.

MLP → CNN → RoBERTa → T5 → T5 fine-tuned → Gradio)

3.1 Etapa 1 — Modelo base: MLP + TF-IDF

El modelo base establece la línea de referencia. Se vectoriza el texto con TfidfVectorizer (max_features=10 000, ngram_range=(1,2), min_df=3, max_df=0.95) sobre el training set balanceado por undersampling, y se entrena un MLPClassifier de sklearn con una capa oculta de 48 unidades, activación ReLU, optimizador Adam y regularización L2 (alpha=5e-4).

Para simular entrenamiento por épocas sobre sklearn), se utilizó warm_start=True con max_iter=1 por iteración, implementando manualmente un early stopping basado en val_loss con paciencia de 3 épocas. Se guardan los mejores coeficientes observados y se reemplazan los finales del modelo.

Artefactos exportados: mlp_model.joblib, mlp_vectorizer.joblib, mlp_metrics.csv.

3.2 Etapa 2 — Arquitectura profunda: 1D-CNN

La 1D-CNN se eligió sobre LSTM/GRU por tres motivos: entrenamiento paralelo por secuencia vs. secuencial, captura efectiva de n-gramas locales (kernel=5) muy apropiada para detectar patrones como "not good" o "highly recommend", y estabilidad superior sobre un volumen de datos grande sin tuning exhaustivo.

Arquitectura (Keras Sequential):

- Embedding(input_dim=10 000, output_dim=64) — embeddings aprendidos de 64 dimensiones.
- Conv1D(filters=96, kernel_size=5, activation=ReLU, l2=5e-4).
- GlobalMaxPooling1D — reduce la dimensión temporal.
- Dropout(0.3) — regularización.
- Dense(48, ReLU, l2=5e-4).
- Dropout(0.3).
- Dense(3, softmax) — salida multiclase.

Entrenamiento con batch_size=64, Adam (lr=1e-3), sparse_categorical_crossentropy, hasta 12 épocas con callbacks EarlyStopping (patience=2, restore_best_weights=True), ReduceLROnPlateau (factor=0.5, patience=1) y ModelCheckpoint del mejor modelo según val_loss. El hiperparámetro max_len=100 se justifica con el percentil 90-95 de la longitud en tokens del training set, priorizando cobertura de contenido sin encarecer el entrenamiento.

Artefactos exportados: cnn_model.keras, cnn_tokenizer.pkl, cnn_label_encoder.pkl, cnn_metrics.csv.

3.3 Etapa 3 — Modelos preentrenados: RoBERTa zero-shot

Para integrar un modelo Transformer se seleccionó cardiffnlp/twitter-roberta-base-sentiment, un RoBERTa-base (~125M parámetros) preentrenado específicamente para clasificación de sentimiento en tres clases (LABEL_0 = negative, LABEL_1 = neutral, LABEL_2 = positive). La elección se justifica por la alineación directa con el problema multiclase y el tamaño razonable para ejecución en GPU estándar.

En esta etapa NO se realiza entrenamiento adicional: el modelo se aplica en modo inferencia directa (zero-shot). El objetivo es cuantificar la capacidad de transferencia de un modelo entrenado sobre tweets al dominio de reseñas de alimentos. Este domain shift es el motor explicativo de los resultados observados.

Para evitar fragilidad en el análisis, los splits train/val/test se procesan por separado con el pipeline de HuggingFace (truncation=True, max_length=512, batch_size=32), en lugar de concatenar el dataframe completo y reconstruir splits por posición.

Artefactos exportados: transformer_metrics.csv.

3.4 Etapa 4 — Componente generativo: T5-small zero-shot

El componente generativo usa T5-small (~60M parámetros, arquitectura encoder-decoder) para summarization. La elección se justifica por tamaño manejable en GPU gratuita de Kaggle, arquitectura text-to-text nativa y disponibilidad de tokenizer y pesos vía HuggingFace.

Se evalúa primero en modo zero-shot para establecer una línea base sin adaptación. El prompt usado es "summarize: <texto_review>". La generación se realiza con beam search (num_beams=4), max_length=32 tokens, min_length=4, early_stopping=True.

La evaluación cuantitativa se realiza con ROUGE-1/2/L sobre una muestra controlada de 500 reseñas del test set, por el costo computacional de beam search sobre el test completo. La muestra es aleatoria estratificada (random_state=42) para reproducibilidad.

Mientras que MLP, CNN y RoBERTa clasifican el sentimiento, T5 produce un resumen textual del contenido. Esto complementa la tarea de clasificación permitiendo presentar reseñas largas en forma compacta.

Artefactos exportados: generative_metrics.csv, generative_predictions_eval.csv.

3.5 Etapa 5 — Fine-tuning parcial y despliegue

Se realiza fine-tuning parcial de T5-small sobre los pares (review ,summary) del training set. La estrategia de congelamiento selectivo:

- Congelados: encoder completo + los primeros 4 bloques del decoder.
- Entrenables: últimos 2 bloques del decoder + final_layer_norm + lm_head.
- Resultado: ~41 % de los parámetros totales son entrenables (~25M de ~60M).

Esta estrategia reduce el costo computacional respecto a un fine-tuning completo y mitiga el riesgo de sobreajuste, permitiendo adaptar las capas superiores al estilo específico de los Summary del dataset.

Configuración de entrenamiento (Seq2SeqTrainer de HuggingFace):

- learning_rate=2e-4, per_device_train_batch_size=8, weight_decay=0.01.
- num_train_epochs=1 (limitado por tiempo de cómputo en GPU T4 gratuita).
- fp16=True (mixed precision) para acelerar.
- max_input_length=256, max_target_length=32.

Despliegue: el modelo fine-tuned se envuelve en una función de inferencia y se expone mediante una interfaz Gradio con share=True, que genera una URL pública temporal (7 días). La interfaz acepta una reseña en inglés y devuelve el resumen generado en tiempo real con un tiempo de respuesta promedio < 1 segundo en GPU T4.

Artefactos exportados: t5_finetuned_final/, finetuned_metrics.csv, finetuned_predictions_eval.csv, comparacion_base_vs_finetuned.csv.

4. Experimentos realizados

4.1 Análisis exploratorio (Etapa 1)

El EDA se estructuró en tres niveles:

- Nivel descriptivo: distribución de clases, estadísticas de longitud del texto, valores nulos.
- Nivel comparativo por clase: longitud del texto por sentimiento, top unigramas y bigramas por clase con filtro de stopwords, ejemplos representativos.
- Nivel operativo: limpieza del texto, split estratificado 70/15/15, exportación de CSVs para las siguientes etapas.

El análisis por clase reveló que las reseñas negativas tienden a ser marginalmente más largas que las positivas (más detalle de las quejas) y que los bigramas discriminativos son fuertes indicadores del sentimiento ("waste money", "highly recommend", "not worth").

Limitación reconocida de la limpieza: se eliminan números ("5/5") y se fragmentan contracciones ("don't" → "don t"). Esto afecta principalmente a los modelos de las Etapas 1 y 2. En las Etapas 3 y 4 el texto entra al tokenizer nativo del modelo preentrenado, reduciendo el impacto.

4.2 Protocolo de evaluación

Para las tareas de clasificación (Etapas 1-3), en cada modelo se reporta:

- Accuracy global sobre validación y test.
- Precision, Recall y F1 por clase (classification_report).
- Precision, Recall y F1 macro (peso equivalente por clase, sensible al desbalance).
- Precision, Recall y F1 weighted (ponderado por support).
- Matriz de confusión sobre test.

Para la tarea generativa (Etapas 4-5) se usa:

- ROUGE-1, ROUGE-2, ROUGE-L y ROUGE-Lsum sobre una muestra de 500 reseñas de test (misma muestra en ambas etapas para comparabilidad).
- Análisis cualitativo lado a lado: review / summary real / summary generado sobre una submuestra controlada.

4.3 Análisis de errores (MLP)

El análisis cualitativo de errores extremos (positive confundido con negative y viceversa) reveló los tres patrones de falla más frecuentes del enfoque bag-of-words:

- Negación contextual: reseñas con apertura negativa seguida de giro positivo ("was skeptical… turned out great") son clasificadas por la polaridad media ponderada, ignorando el orden.

- Sarcasmo y comparaciones: frases como "worst chocolate ever , just kidding, it's amazing" combinan tokens negativos con sentido positivo final; TF-IDF no modela esto.
- Reseñas cortas con adjetivos aislados: textos de 3-5 tokens concentran la decisión en un solo n-grama, sin contexto compensatorio.

Estas limitaciones motivan cuantitativamente la necesidad de arquitecturas que modelen contexto (1D-CNN captura n-gramas locales,Transformers modelan contexto bidireccional completo).

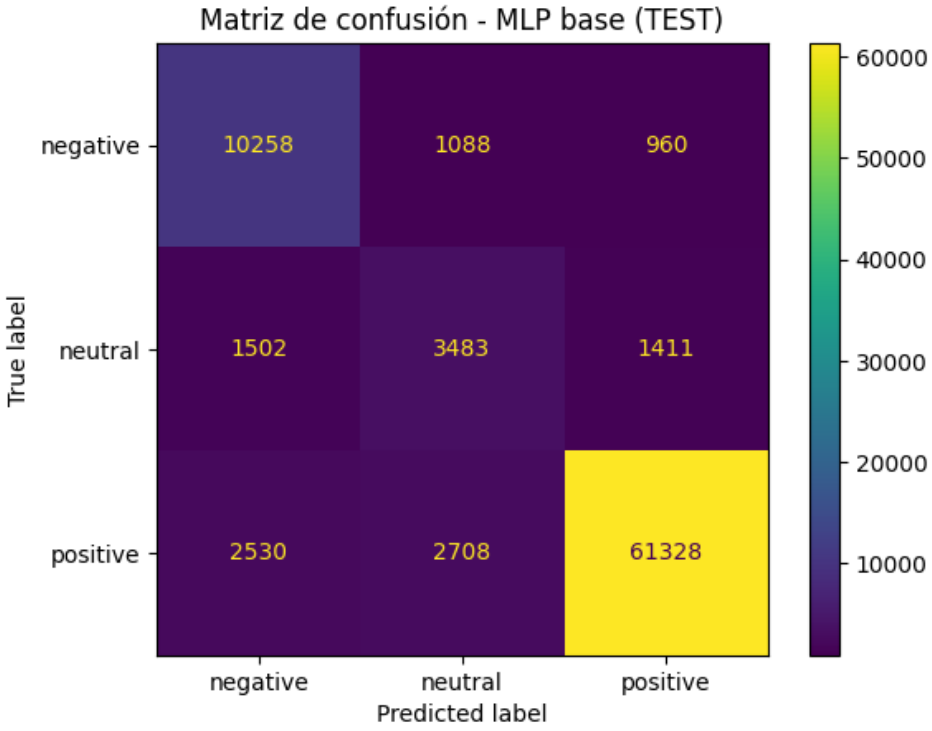

Figura — Matriz de confusión del MLP sobre TEST (exportada de NB2)

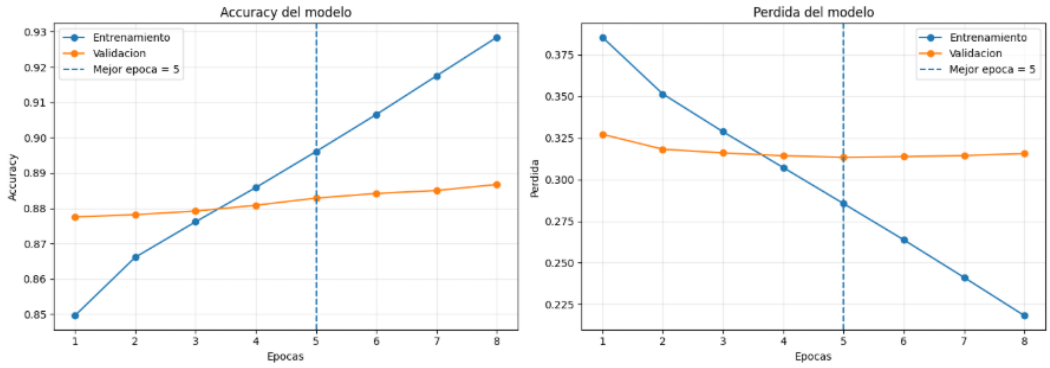

Figura — Curvas de accuracy y loss por época durante el entrenamiento del MLP (exportadas de NB2)

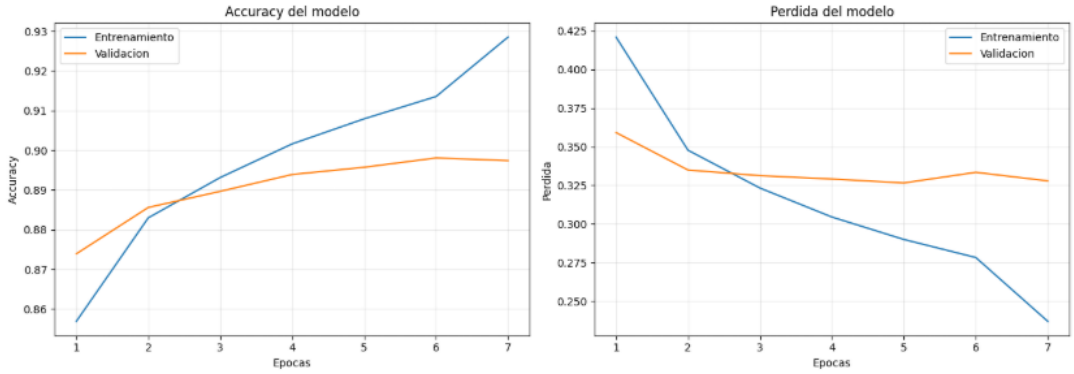

Figura — Curvas de accuracy y loss por época durante el entrenamiento de la 1D-CNN (exportadas de NB3)

5. Resultados

5.1 Comparativa — Clasificación de sentimiento

Métricas sobre el conjunto de TEST (85 268 reseñas):

Métrica	MLP (Etapa 1)	1D-CNN (Etapa 2)	RoBERTa zero-shot (Etapa 3)
Accuracy	0.8804	0.8954	0.8344
F1 macro	0.7408	0.7355	0.6166
F1 weighted	0.8846	0.8914	0.8376
Precision macro	0.7197	0.7540	0.6157
Precision weighted	0.8911	0.8889	0.8409
Recall macro	0.7665	0.7230	0.6182
Recall weighted	0.8804	0.8954	0.8344

Observación importante: no hay un ganador absoluto entre MLP y 1D-CNN. La CNN gana en Accuracy (0.8954 vs 0.8804) y Precision macro (0.7540 vs 0.7197), mientras que el MLP gana en F1 macro (0.7408 vs 0.7355) y Recall macro (0.7665 vs 0.7230). Esto significa que la CNN comete menos falsos positivos pero detecta menos casos de las clases minoritarias; el MLP es más balanceado entre clases.

El Transformer zero-shot (RoBERTa) es consistentemente inferior en todas las métricas. Este resultado NO es un fallo de la arquitectura Transformer en general, sino del modo zero-shot: el modelo fue preentrenado sobre tweets, no reseñas de comida, y arrastra un gap de dominio sustancial. Con fine-tuning sobre reseñas, es esperable que supere a MLP y CNN.

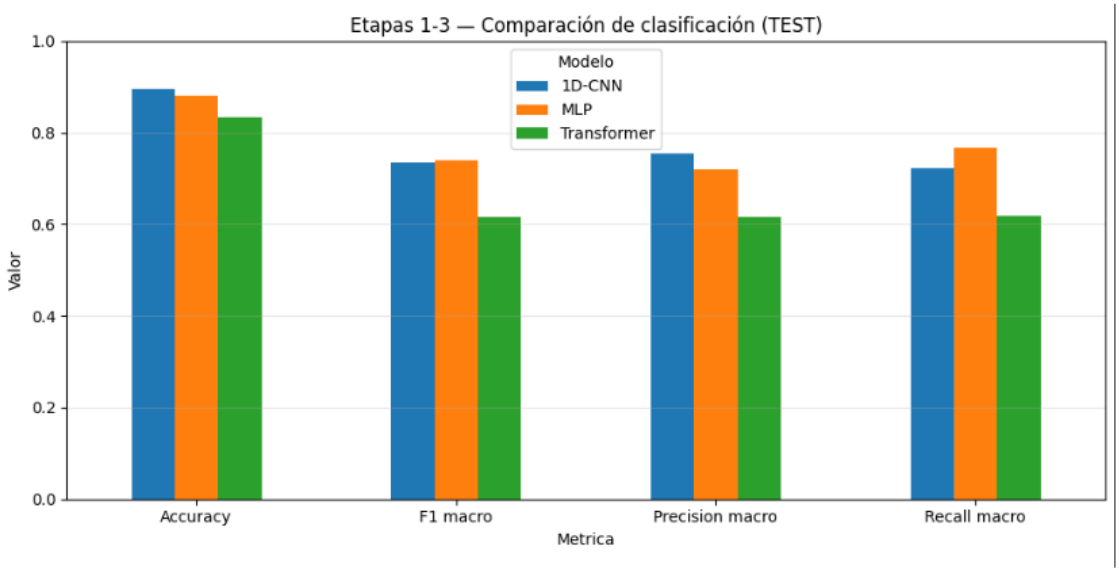

Figura — Gráfico de barras — Comparación de clasificación sobre TEST

5.2 Comparativa — Componente generativo

ROUGE sobre 500 reseñas del test set, misma muestra para ambos modelos:

Métrica	T5-small zero-shot (Etapa 4)	T5-small fine-tuned parcial (Etapa 5)	Mejora relativa
ROUGE-1	0.0849	0.1359	+60.07 %
ROUGE-2	0.0232	0.0469	+102.16 %
ROUGE-L	0.0783	0.1346	+71.90 %

El fine-tuning parcial produce una mejora muy significativa en las tres métricas ROUGE. La mejora especialmente alta en ROUGE-2 (+102 %) indica que el modelo aprendió a producir bigramas consistentes con el estilo del dataset — no solo palabras sueltas, sino combinaciones cortas y coherentes con el formato de los Summary originales.

Interpretación del costo-beneficio: con solo ~41 % de los parámetros del modelo entrenables y una única época de fine-tuning, se duplicó ROUGE-2 y se ganó ~70 % en ROUGE-L. Esto demuestra que adaptar al dominio un modelo preentrenado es mucho más efectivo que entrenar desde cero, y que el fine-tuning parcial es una estrategia de alto valor cuando el tiempo y cómputo son limitados.

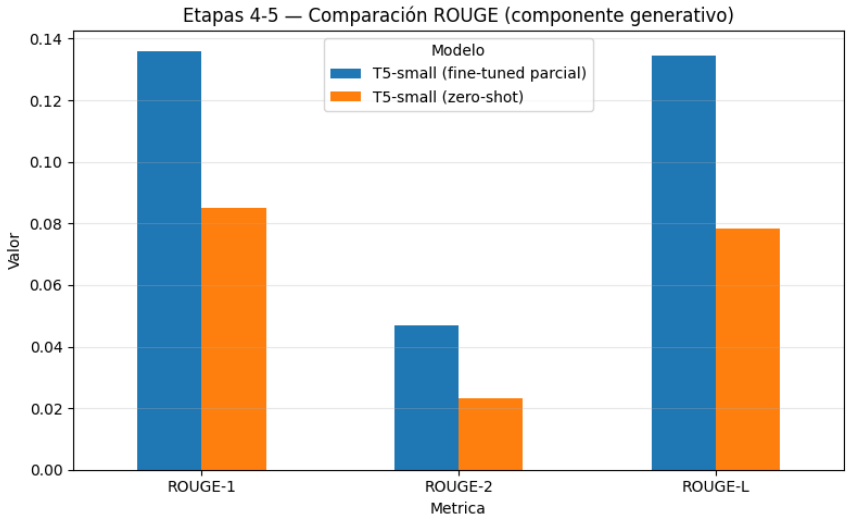

Figura — Gráfico de barras — Comparación ROUGE T5 zero-shot vs fine-tuned parcial (exportado del NB7)

5.3 Análisis cualitativo del componente generativo

Los valores de ROUGE son bajos en términos absolutos por una razón estructural del dataset: los Summary originales son etiquetas ultracortas (p. ej. "great taffy", "perfect gift", 3-5 palabras), mientras que T5 tiende a generar frases más largas extraídas o parafraseadas de la reseña. Esto penaliza el solapamiento léxico (ROUGE) aun cuando el contenido es semánticamente razonable.

Ejemplo representativo (zero-shot, antes de fine-tuning):

Review (primeras 150 chars):

"a friend of mine recently had miscarriage and i wanted to send her something to brighten her day… i stumbled across funkychunky… very happy phone call from my friend…"

Summary real: "perfect gift"

Summary generado (zero-shot): "a friend of mine recently had miscarriage and i wanted to send her something to brighten her day. i decided to look"

Tras el fine-tuning parcial, el modelo aprende a producir resúmenes más cortos y cercanos al estilo de etiqueta, lo que se refleja en la mejora sustancial en todas las métricas ROUGE.

5.4 Despliegue final

El modelo T5 fine-tuned se expone a través de una interfaz Gradio con URL pública temporal (válida 7 días desde la última ejecución). La interfaz acepta reseñas en inglés y devuelve el resumen generado con beam search (num_beams=4). Tiempo de respuesta promedio en GPU T4: < 1 segundo

6. Limitaciones y trabajo futuro

6.1 Limitaciones identificadas

- Clase neutral: sigue siendo la más difícil de clasificar en todas las etapas (F1 por clase ≈ 0.45-0.50) por su naturaleza ambigua y su menor representación en el dataset (~7.5 %).
- Fine-tuning limitado a 1 epoch por restricción de tiempo en GPU gratuita. Es probable que épocas adicionales (3-5) mejoren ROUGE significativamente.
- Evaluación generativa únicamente con ROUGE: solapamiento léxico, no semántico. Un resumen correcto en significado pero con diferente elección léxica penaliza la métrica.

7. Conclusiones

El proyecto demuestra la viabilidad de un sistema progresivo de Deep Learning aplicado a reseñas de e-commerce, cubriendo tanto clasificación como generación. Los hallazgos principales se resumen así:

Sobre la clasificación de sentimiento (Etapas 1-3)

- La 1D-CNN mejora la Accuracy global (0.8954 vs 0.8804) y la Precision macro respecto al MLP base. Sin embargo, el MLP preserva mejor el balance entre clases (mayor F1 y Recall macro).
- La elección entre ambos depende del criterio de optimización: Accuracy global para la CNN, equilibrio entre clases para el MLP. En este sentido, no existe un ganador absoluto.
- El Transformer zero-shot (RoBERTa) NO supera a los modelos entrenados en este dataset. Esto es consistente con la existencia de un gap de dominio (tweets vs. reseñas de comida). Este resultado NO invalida el uso de Transformers: valida que la adaptación al dominio (fine-tuning) es necesaria.

Sobre el componente generativo (Etapas 4-5)

- T5-small en modo zero-shot alcanza ROUGE-L ≈ 0.08, limitado por la brecha de estilo (Summary ultracortos en el dataset vs. frases largas generadas por T5).
- Tras fine-tuning parcial (solo ~41 % de parámetros entrenables, 1 epoch), las métricas mejoran +60 % en ROUGE-1, +102 % en ROUGE-2 y +72 % en ROUGE-L.
- El fine-tuning parcial demuestra ser una estrategia de alto costo-beneficio: gran mejora con tiempo y cómputo limitados.

Sobre el despliegue

- El modelo fine-tuned se expone con éxito a través de Gradio, ofreciendo una demostración funcional del sistema accesible vía URL pública.